

- SVM (support vector machine)
  - features
  - definition (hard margin)
    - geometric margin derivation
  - target
  - solve
  - soft margin

# SVM (support vector machine)

## features

### 间隔最大的线性分类器

(感知机为可行NN, 无间隔要求),  
通过使用核技巧, 可以进阶为非线性分类器。

本文着眼于间隔最大的线性分类器。

## definition (hard margin)

**hard margin**满足严格分类。

对点集 $\{(\vec{x}_i, y_i)\}$ , 令 $\vec{w} \cdot \vec{x} + b = 0$ 为超平面, 则几何间隔为 $\gamma_i = y_i(\frac{\vec{w}}{\|\vec{w}\|} \cdot \vec{x}_i + \frac{b}{\|\vec{w}\|})$ 。

## geometric margin derivation

记 $\vec{x}_0$ 为 $\vec{x}$ 在超平面上的投影, 则有 $\vec{x} = \vec{x}_0 + \gamma \frac{\vec{w}}{\|\vec{w}\|}$ , 且满足 $\vec{w} \cdot \vec{x}_0 + b = 0$ ,

代入得,  $\vec{w}(\vec{x} - y \frac{\vec{w}}{\|\vec{w}\|}) + b = 0$ , 解出 $y = \frac{\vec{w} \cdot \vec{x} + b}{\|\vec{w}\|}$ ,

$$\tilde{\gamma} = y\gamma = \frac{\hat{\gamma}}{\|\vec{w}\|}$$

对一组固定的 $pair(\vec{w}, b)$ , 我们可以得到其对应的一组 $\{\gamma_i\}$ , 则其间隔为 $\gamma = \min_i \gamma_i$ 。

# target

**target:**  $\max_{\vec{w}, b} \gamma$

由def可知,  $\gamma_i \geq \gamma$ , 即  $y_i(\frac{\vec{w}}{\|\vec{w}\|} \cdot \vec{x}_i + \frac{b}{\|\vec{w}\|}) \geq \gamma$ , 进一步的, 有  $y_i(\frac{\vec{w}}{\|\vec{w}\|_\gamma} \cdot \vec{x}_i + \frac{b}{\|\vec{w}\|_\gamma}) \geq 1$ .

令  $\vec{W} = \frac{\vec{w}}{\|\vec{w}\|_\gamma}$ ,  $B = \frac{b}{\|\vec{w}\|_\gamma}$ , 则  $y_i(\vec{W} \cdot \vec{x}_i + B) \geq 1$ .

$\|\vec{W}\| = \frac{\|\vec{w}\|}{\|\vec{w}\|_\gamma} = \frac{1}{\gamma}$ , 则  $\max \gamma \Leftrightarrow \max \frac{1}{\|\vec{W}\|} \Leftrightarrow \min \frac{1}{2} \|\vec{W}\|^2$

在下文中, 用  $\vec{w}$  代替  $\vec{W}$ , 用  $b$  代替  $B$ , 需要注意。

**target:**  $\min_{\vec{w}, b} \frac{1}{2} \|\vec{w}\|^2, \text{ s.t. } y_i(\vec{w} \cdot \vec{x}_i + b) \geq 1$

这是一个含有不等式约束的凸二次规划问题, 考虑使用拉格朗日乘子法和dual problem。

构造无约束拉格朗日目标函数,  $L(\vec{w}, b, \vec{\alpha}) = \frac{1}{2} \vec{w}^2 - \sum \alpha_i (y_i(\vec{w} \cdot \vec{x}_i + b) - 1)$ ,

记  $\theta(\vec{w}, b) = \max_{\alpha_i \geq 0} L(\vec{w}, b, \vec{\alpha}) = \begin{cases} \frac{1}{2} \vec{w}^2, & (\forall i, y_i(\vec{w} \cdot \vec{x}_i + b) \geq 1) \\ +\infty, & (\exists i, y_i(\vec{w} \cdot \vec{x}_i + b) < 1) \end{cases}$

**target:**  $\min_{\vec{w}, b} \max_{\alpha_i \geq 0} L(\vec{w}, b, \vec{\alpha}) = p^*$

利用拉格朗日函数对偶性,  $\max_{\alpha_i \geq 0} \min_{\vec{w}, b} L(\vec{w}, b, \vec{\alpha}) = d^*$

若要满足  $p^* = d^*$ , 则需要满足**凸优化**和**KKT**条件。

# solve

**KKT:**

$$\begin{cases} \alpha_i \geq 0 \\ y_i(\vec{w} \cdot \vec{x}_i + b) - 1 \geq 0 \\ \alpha_i(y_i(\vec{w} \cdot \vec{x}_i + b) - 1) = 0 \end{cases}$$

在满足**KKT**的情况下, 易证**凸优化**成立。

求极值, 需要满足

$$\begin{cases} \frac{\partial L}{\partial \vec{w}} = 0 = \vec{w} - \sum \alpha_i y_i \vec{x}_i \\ \frac{\partial L}{\partial b} = 0 = - \sum \alpha_i y_i \end{cases}$$

代入目标函数, 有

$$\begin{aligned}
L(\vec{w}, b, \vec{\alpha}) &= \frac{1}{2} \left( \sum \alpha_i y_i \vec{x}_i \right)^2 - \sum \alpha_i \{ y_i [(\sum \alpha_j y_j \vec{x}_j) \cdot \vec{x}_i + b] - 1 \} \\
&= -\frac{1}{2} \left( \sum \alpha_i y_i \vec{x}_i \right)^2 - b \sum \alpha_i y_i + \sum \alpha_i \\
&= -\frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j (\vec{x}_i \cdot \vec{x}_j) + \sum \alpha_i
\end{aligned}$$

$\max L = \min -L$ , 用SMO求得 $\vec{\alpha}$ , 则 $\vec{w} = \sum \alpha_i y_i \vec{x}_i$ , 下面用反证法求 $b$ 。

由KKT条件, 有 $\alpha_i (y_i (\vec{w} \cdot \vec{x}_i + b) - 1) = 0$ 。若 $\forall \alpha_i = 0$ , 则 $\vec{w} = 0$ , 矛盾, 故 $\exists \alpha_j \neq 0$ , 则解 $y_i (\vec{w} \cdot \vec{x}_i + b) - 1 = 0$ , 可得 $b = \frac{1}{y_i} - \vec{w} \cdot \vec{x}_i$ 。

## soft margin

**soft margin**允许某些点不满足约束 $y_i (\vec{w} \cdot \vec{x}_i + b) \geq 1$ 。

采用hinge损失, 将原问题转化为 $\min_{\vec{w}, b, \vec{\xi}} \frac{1}{2} \vec{w}^2 + C \sum \xi_i$ , 满足 $\begin{cases} y_i (\vec{w} \cdot \vec{x}_i + b) \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases}$

$\vec{\xi}$ 为松弛变量,  $\xi_i = \max(0, 1 - y_i (\vec{w} \cdot \vec{x}_i + b))$ ;  $C > 0$ 称为惩罚函数。

$$\begin{aligned}
L(\vec{w}, b, \vec{\xi}, \vec{\alpha}, \vec{\mu}) &= \frac{1}{2} \vec{w}^2 + C \sum \xi_i - \sum \alpha_i [y_i (\vec{w} \cdot \vec{x}_i + b) - (1 - \xi_i)] - \sum \mu_i \xi_i \\
\theta(\vec{w}, b, \vec{\xi}) &= \max_{\alpha_i \geq 0, \mu_i \geq 0} L(\vec{w}, b, \vec{\xi}, \vec{\alpha}, \vec{\mu}) = \\
&\begin{cases} \frac{1}{2} \vec{w}^2 + C \sum \xi_i, & (\forall i, \begin{cases} y_i (\vec{w} \cdot \vec{x}_i + b) - (1 - \xi_i) \geq 0 \\ \xi_i \geq 0 \end{cases}) \\ +\infty, & otherwise \end{cases}
\end{aligned}$$

**target:**  $\min_{\vec{w}, b, \vec{\xi}} \max_{\vec{\alpha} \geq 0, \vec{\mu} \geq 0} L(\vec{w}, b, \vec{\xi}, \vec{\alpha}, \vec{\mu}) = p^*$

$\max_{\vec{\alpha} \geq 0, \vec{\mu} \geq 0} \min_{\vec{w}, b, \vec{\xi}} L(\vec{w}, b, \vec{\xi}, \vec{\alpha}, \vec{\mu}) = d^*$

**KKT:**

$$\begin{cases} \alpha_i \geq 0 \\ y_i (\vec{w} \cdot \vec{x}_i + b) - (1 - \xi_i) \geq 0 \\ \alpha_i (y_i (\vec{w} \cdot \vec{x}_i + b) - (1 - \xi_i)) = 0 \\ \mu_i \geq 0 \\ \xi_i \geq 0 \\ \mu_i \xi_i = 0 \end{cases}$$

$$\begin{cases} \frac{\partial L}{\partial \vec{w}} = 0 = \vec{w} - \sum \alpha_i y_i \vec{x}_i \\ \frac{\partial L}{\partial b} = 0 = -\sum \alpha_i y_i \\ \frac{\partial L}{\partial \vec{\xi}} = 0 = C - \vec{\alpha} - \vec{\mu} \end{cases}$$

代入得 $L(\vec{w}, b, \vec{\xi}, \vec{\alpha}, \vec{\mu}) = -\frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \vec{x}_i \cdot \vec{x}_j + \sum \alpha_i$

$SMO$ 求得 $\vec{\alpha}$ , 则 $\vec{w} = \sum \alpha_i y_i \vec{x}_i$ 。

对于soft margin而言,  $b$ 是多解的。